PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO

Alocação preditiva de recursos em nuvem via previsão de carga com Redes Neurais para minimização de custos operacionais

Gabriel Lobo de Sant'Anna Rosas

PROJETO FINAL DE GRADUAÇÃO

CENTRO TÉCNICO CIENTÍFICO - CTC

DEPARTAMENTO DE INFORMÁTICA

Curso de Graduação em Engenharia de Computação

Rio de Janeiro, Novembro de 2026

Pontifícia Universidade Católica
do Rio de Janeiro



Gabriel Lobo de Sant'Anna Rosas

Alocação preditiva de recursos em nuvem via previsão de carga com Redes Neurais para minimização de custos operacionais

Relatório de Projeto Final I, apresentado ao programa de Graduação do Departamento de Informática da PUC-Rio como requisito parcial para a obtenção do título de Engenheiro de Computação.

Orientador: Adriano Francisco Branco
Co-orientador: Jonatas dos Santos Grosman

Rio de Janeiro
Novembro de 2026

Resumo

Rosas, Gabriel Lobo de Sant'Anna. Branco, Adriano Francisco. Grosman, Jonatas dos Santos. **Alocação preditiva de recursos em nuvem via previsão de carga com Redes Neurais para minimização de custos operacionais**. Rio de Janeiro, 2026. 35 p. Relatório de Projeto Final I – Departamento de Informática. Pontifícia Universidade Católica do Rio de Janeiro.

Provedores de nuvem precisam decidir continuamente quantas instâncias manter ativas: recursos em excesso elevam o custo, e recursos insuficientes violam o acordo de nível de serviço. A alocação reativa só ajusta a capacidade depois de observar a mudança na demanda e, por isso, chega atrasada nos picos. Este trabalho investiga o quanto a qualidade da previsão de carga reduz o custo de alocação sem aumentar as violações de serviço. Para atribuir as diferenças ao previsor, a política de alocação é mantida fixa e apenas o previsor muda. São comparados métodos tradicionais de previsão (ingênuo, média móvel, sazonal ingênuo, Holt-Winters e ARIMA) e uma rede neural recorrente do tipo GRU, além de uma política reativa e do dimensionamento estático pelo pico do treino, sobre séries de utilização agregadas a partir do rastro público de um *cluster* da Alibaba e avaliadas em um ambiente de simulação. As métricas são o custo normalizado pelo de um oráculo e a fração de intervalos com violação. Os resultados preliminares mostram que, com limite de 5% de intervalos com violação, ajustar a capacidade à demanda, com ou sem previsão, reduz o custo em cerca de 35% frente ao dimensionamento estático, mas que o melhor previsor fica apenas 1,7% abaixo da política reativa, diferença que uma única janela de teste não permite atribuir ao previsor, e que a GRU é competitiva com o ARIMA, sem vantagem clara. No Projeto Final II, a avaliação incorpora a memória e se estende ao rastro do Google.

Palavras-chave

Computação em nuvem; Alocação de recursos; Previsão de carga; Redes neurais; Acordo de nível de serviço.

Abstract

Rosas, Gabriel Lobo de Sant'Anna. Branco, Adriano Francisco (Advisor). Grosman, Jonatas dos Santos (Co-advisor). **Predictive cloud resource allocation via workload forecasting with neural networks for operating cost minimization**. Rio de Janeiro, 2026. 35 p. Undergraduate Thesis I – Departamento de Informática. Pontifícia Universidade Católica do Rio de Janeiro.

Cloud providers must continuously decide how many instances to keep active: excess resources raise costs, while insufficient resources violate the service level agreement. Reactive allocation adjusts capacity only after observing a change in demand and therefore lags behind peaks. This work investigates how much the quality of workload forecasting reduces allocation cost without increasing service violations. To attribute differences to the forecaster, the allocation policy is kept fixed and only the forecaster changes. Traditional forecasting methods (naive, moving average, seasonal naive, Holt-Winters and ARIMA) and a recurrent neural network of the GRU type are compared, together with a reactive policy and static sizing at the training peak, using utilization series aggregated from a public Alibaba cluster trace and evaluated in a simulation environment. The metrics are the cost normalized by that of an oracle and the fraction of intervals with violations. Preliminary results show that, with a 5% violation limit, adjusting capacity to demand, with or without forecasting, reduces cost by about 35% compared with static sizing, but that the best forecaster is only 1.7% cheaper than the reactive policy, a difference that a single test window cannot attribute to the forecaster, and that the GRU is competitive with ARIMA, with no clear advantage. In the second part of the project, the evaluation incorporates memory and extends to the Google trace.

Keywords

Cloud computing; Resource allocation; Workload forecasting; Neural networks; Service level agreement.

Sumário

1 Introdução **9**
1.1 Motivação 9
1.2 Definição do problema 9
1.3 Justificativa 10
1.4 Escopo e delimitação 10
1.5 Organização do documento 10

2 Situação Atual **11**
2.1 Conceitos e terminologia 11
2.2 Abordagens para previsão de carga 13
2.3 Abordagens para alocação de recursos 15
2.4 Comparativo dos trabalhos relacionados e lacuna 16
2.5 Tecnologias utilizadas 18

3 Objetivos do trabalho **19**
3.1 Solução proposta 19
3.2 Objetivos 20
3.3 Escopo do sistema 22
3.4 Usuários e situações apoiadas 22
3.5 Avanços em relação às soluções existentes 23
3.6 Itens a serem implementados e apresentados à banca 23

4 Revisão do Plano de Ação **24**
4.1 Plano previsto 24
4.2 Atividades realizadas 24
4.3 Dificuldades encontradas 25
4.4 Resultados preliminares 25

5 Cronogramas **29**
5.1 Projeto Final I 29
5.2 Projeto Final II 29

Referências **30**

A Erro de previsão por horizonte **33**

B Parâmetros dos previsores e do Projeto Final II **35**

Lista de figuras

Figura 3.1 Arquitetura da solução proposta. 19

Figura 4.1 Demanda de processador e cobertura do rastro da Alibaba. 25
Figura 4.2 Custo normalizado contra fração de intervalos com violação no teste, com $L = 1$. 27

Lista de tabelas

Tabela 2.1 Comparativo entre os trabalhos relacionados e a proposta deste trabalho. 17
Tabela 2.2 Ferramentas utilizadas em cada etapa do *pipeline*. 18

Tabela 3.1 Questões de pesquisa. 20
Tabela 3.2 Objetivos específicos, questões de pesquisa associadas e situação ao fim do Projeto Final I. 21
Tabela 3.3 Parâmetros da alocação e do protocolo de avaliação. 22

Tabela 4.1 Erro das previsões no teste com $h = 1$. 26
Tabela 4.2 Pontos de operação no teste, com $L = 1$ e $L = 2$. 26
Tabela 4.3 Demanda não atendida, capacidade ociosa e alterações no teste, com $L = 1$. 28

Tabela 5.1 Cronograma previsto e realizado do Projeto Final I, em 2026. 29
Tabela 5.2 Cronograma proposto para o Projeto Final II. 29

Tabela A.1 Erro das previsões na validação, por horizonte h. 33
Tabela A.2 Erro das previsões no teste, por horizonte h. 34

Tabela B.1 Parâmetros dos previsores e das janelas e sementes do Projeto Final II. 35

Lista de Abreviaturas

AIC – Critério de informação de Akaike (*Akaike Information Criterion*)

ARIMA – Modelo autorregressivo integrado de médias móveis (*AutoRegressive Integrated Moving Average*)

CPU – Unidade central de processamento (*Central Processing Unit*)

GPU – Unidade de processamento gráfico (*Graphics Processing Unit*)

GRU – *Gated Recurrent Unit*

HBNN – Rede neural bayesiana (*Bayesian Neural Network*), na nomenclatura de Rossi et al.

HPA – *Horizontal Pod Autoscaler*

LSTM – *Long Short-Term Memory*

LSTMD – LSTM com saída distribucional (*LSTM Distributional*)

MAE – Erro absoluto médio (*Mean Absolute Error*)

MAPE – Erro percentual absoluto médio (*Mean Absolute Percentage Error*)

MSE – Erro quadrático médio (*Mean Squared Error*)

OE – Objetivo específico

PF – Projeto Final

QoS – Qualidade de serviço (*Quality of Service*)

QP – Questão de pesquisa

RMSE – Raiz do erro quadrático médio (*Root Mean Squared Error*)

RNN – Rede neural recorrente (*Recurrent Neural Network*)

SLA – Acordo de nível de serviço (*Service Level Agreement*)

SLI – Indicador de nível de serviço (*Service Level Indicator*)

SLO – Objetivo de nível de serviço (*Service Level Objective*)

SQL – *Structured Query Language*

1
Introdução

1.1
Motivação

A computação em nuvem consolidou-se como a principal forma de disponibilizar infraestrutura computacional. O provedor mantém grandes centros de dados e precisa decidir, de forma contínua, quanto de processamento, memória e armazenamento deixar disponível, e, com a demanda crescente, impulsionada por aplicações de Inteligência Artificial e de análise de dados, a gestão eficiente desses recursos tornou-se central para a sustentabilidade econômica dos provedores (ROSSI et al., 2025).

A carga de trabalho, porém, não é constante: apresenta picos, padrões periódicos e variações aparentemente aleatórias. A abordagem mais comum é a alocação reativa, que ajusta os recursos depois de observar uma mudança na demanda, normalmente por regras de limiar sobre a utilização; como a reação chega atrasada, ela tende a degradar o desempenho nos picos e a desperdiçar recursos nos períodos de baixa (BODRA; KHAIRNAR, 2025). Manter recursos em excesso (superprovisionamento) garante a qualidade do serviço, mas eleva o custo; manter recursos de menos (subprovisionamento) reduz o custo, mas provoca violações dos Acordos de Nível de Serviço (*Service Level Agreements*, SLA) firmados com os clientes.

A alocação preditiva usa o histórico de uso para antecipar a demanda e provisionar recursos antes que sejam necessários (BODRA; KHAIRNAR, 2025), o que faz da previsão de carga uma pré-condição para otimizar a alocação (ROSSI et al., 2025). Essa previsão foi tradicionalmente tratada com modelos estatísticos lineares, como o modelo autorregressivo integrado de médias móveis (ARIMA) (CALHEIROS et al., 2015), e, mais recentemente, com redes neurais recorrentes, inclusive em abordagens que consideram processador e memória simultaneamente (XU et al., 2022).

1.2
Definição do problema

O problema tem duas partes encadeadas. A primeira é de previsão: dado o histórico de utilização de um *cluster*, amostrado em intervalos regulares, estimar a demanda de processador e de memória em um horizonte curto. A segunda é de decisão: a partir dessa estimativa, determinar quantas instâncias (máquinas virtuais ou contêineres) manter ativas em cada intervalo, o que pode ser formulado como a minimização do custo operacional sujeita a uma restrição de qualidade de serviço:

$$\min_{n_1,\ldots,n_T} \sum_{t=1}^{T} c \cdot n_t \quad \text{sujeito a} \quad \frac{1}{T}\sum_{t=1}^{T} \mathbf{1}\left[\, d_t > k \cdot n_t \,\right] \leq \varepsilon, \tag{1-1}$$

em que n_t é o número de instâncias ativas no intervalo t, c é o custo de uma instância por intervalo, k é a capacidade de uma instância, d_t é a demanda real, $\mathbf{1}[\cdot]$ é a função indicadora e ε é a fração máxima tolerada de intervalos com violação de SLA. Como a decisão é tomada com antecedência L (Seção 2.1.3), antes de d_t ser conhecida, ela depende de uma previsão, e a Equação 3-1 define como a restrição é verificada na prática.

1.3 Justificativa

A relevância do problema é econômica e operacional. Cada ponto percentual de recursos ociosos representa custo para o provedor, e cada violação de SLA representa perda de qualidade percebida pelo cliente e, eventualmente, penalidades contratuais. Apesar do volume de trabalhos sobre previsão de carga, nos trabalhos revisados falta uma avaliação de ponta a ponta, com dados públicos, que meça quanto a previsão reduz o custo de alocação quando redes neurais e métodos tradicionais são submetidos à mesma política, lacuna discutida na Seção 2.4.

1.4 Escopo e delimitação

Incluído. Rastros públicos da Alibaba (ALIBABA GROUP, 2018) e do Google (WILKES, 2020), agregados em séries de uso de processador e de memória; horizontes de previsão curtos, na escala de minutos; alocação em um ambiente de simulação, com custo por instância ativa e violação de SLA nos intervalos em que a demanda excede a capacidade; e comparação entre uma rede neural e métodos tradicionais de previsão sob a mesma política de alocação, ao lado das políticas de referência da Seção 3.1.

Fora do escopo. Implantação em uma nuvem real, posicionamento e migração de máquinas virtuais entre servidores físicos, consumo de energia, múltiplos provedores e aprendizado por reforço para a decisão. Na simulação, o posicionamento segue a política padrão do simulador, a mesma para todos os previsores.

1.5 Organização do documento

O Capítulo 2 apresenta os conceitos, as abordagens existentes e as tecnologias utilizadas; o Capítulo 3, a solução proposta e os objetivos; o Capítulo 4, a revisão do plano de ação e os resultados preliminares; e o Capítulo 5, os cronogramas do Projeto Final I (PF I) e do Projeto Final II (PF II).

2
Situação Atual

Este capítulo define a terminologia (Seção 2.1), descreve as abordagens existentes para previsão de carga e para alocação de recursos, com suas limitações (Seções 2.2 e 2.3), compara os trabalhos mais próximos desta proposta (Seção 2.4) e apresenta as tecnologias utilizadas (Seção 2.5).

2.1
Conceitos e terminologia

2.1.1
Elasticidade, carga de trabalho e séries temporais

Uma das características essenciais da computação em nuvem é a elasticidade rápida, isto é, a capacidade de provisionar e liberar recursos, em alguns casos de forma automática, acompanhando a demanda (MELL; GRANCE, 2011). A carga de trabalho (*workload*) de um *cluster*, formada por tarefas em lote, serviços de longa duração e requisições de usuários, se manifesta como utilização de recursos, principalmente processador e memória. Agregada em intervalos regulares de duração Δ, ela forma uma série temporal $y_1, \ldots, y_t$ que combina tendência, padrões periódicos, ruído e picos abruptos (XU et al., 2022). Prever a carga significa estimar $\hat{y}_{t+h}$, o valor da série h intervalos à frente (horizonte de previsão), a partir das w observações mais recentes (janela de entrada). O intervalo em que a previsão é feita é a origem τ: uma previsão feita em τ só pode usar observações até τ. A previsão é univariada quando usa apenas a própria série e multivariada quando incorpora outras, como a memória na previsão do processador (XU et al., 2022).

Entre os rastros (*traces*) públicos de *clusters* reais estão o do Google, com oito células do gerenciador Borg em maio de 2019 (WILKES, 2020), e o da Alibaba de 2018, com cerca de 4.000 máquinas ao longo de oito dias (ALIBABA GROUP, 2018); transformá-los em séries regulares faz parte deste trabalho. Intervalos de cinco minutos são os usuais com esses rastros (ROSSI et al., 2025; XU et al., 2022); Rossi et al. (2025) preveem a demanda dez minutos à frente, horizonte que consideram suficiente para a maioria das aplicações de alocação.

2.1.2
Acordos de nível de serviço

A qualidade de um serviço em nuvem é expressa pelo indicador de nível de serviço (*Service Level Indicator*, SLI), uma medida quantitativa como a latência, pelo objetivo de nível de serviço (*Service Level Objective*, SLO), um valor-alvo para um SLI, e pelo SLA, que formaliza esses objetivos em contrato e define as consequências, geralmente financeiras, de não cumpri-los (BEYER et al., 2016).

Como os rastros públicos não registram a latência percebida pelos usuários, a literatura de alocação aproxima a violação de SLA por medidas derivadas da utilização, como a fração do tempo em que os servidores operam com utilização máxima (BELOGLAZOV; BUYYA, 2012). Este trabalho adota uma aproximação do mesmo tipo: o SLI é medido por intervalo, atendido quando $d_t \leq k \cdot n_t$ na notação da Equação 1-1, e o SLO é que no máximo uma fração ε dos intervalos fique sem atendimento, que é a restrição daquela equação. A simplificação não captura filas nem a degradação gradual perto da saturação, mas permite comparar estratégias de forma consistente.

2.1.3
Provisionamento reativo e preditivo

O escalonamento automático (*autoscaling*) ajusta os recursos de uma aplicação sem intervenção humana; este trabalho trata do escalonamento horizontal, que altera o número de instâncias. Entre as famílias de técnicas classificadas por Lorido-Botran, Miguel-Alonso e Lozano (2014), a distinção central aqui é entre o provisionamento reativo, que decide a partir do que já foi observado, normalmente a utilização corrente, e o preditivo, que decide a partir de uma estimativa $\hat{d}_{t+h}$ da demanda futura ($y_t = d_t$) e já é oferecido por provedores comerciais (AMAZON WEB SERVICES, 2024).

Como uma nova instância leva um tempo para ficar disponível, o atraso de inicialização (MAO; HUMPHREY, 2012), a decisão tomada com as observações até o intervalo τ só passa a valer em $\tau + L$, em que L é a antecedência da decisão (*lead time*), igual a um intervalo mais o atraso de inicialização; sem atraso, $L = 1$. A política reativa decide em τ com a utilização observada em τ, e a preditiva tenta antecipar a demanda de $\tau + L$. Em cada intervalo, a decisão pode errar em duas direções: com $k \cdot n_t > d_t$, a capacidade ociosa $k \cdot n_t - d_t$ é custo sem retorno (superprovisionamento); com $k \cdot n_t < d_t$, parte da demanda não é atendida (subprovisionamento).

2.1.4
Métricas de avaliação

Métricas de previsão. Medem o quanto a previsão se aproxima do valor real, independentemente de como ela será usada. Para N previsões $\hat{y}_i$ e valores reais y_i, as mais comuns são o erro quadrático médio (MSE), sua raiz (RMSE), o erro absoluto médio (MAE) e o erro percentual absoluto médio (MAPE), às quais este trabalho acrescenta o viés, que é o erro médio com sinal:

$$\mathrm{MSE} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2, \qquad \mathrm{RMSE} = \sqrt{\mathrm{MSE}}, \qquad \mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|,$$

$$\mathrm{MAPE} = \frac{100\%}{N}\sum_{i=1}^{N}\left|\frac{y_i - \hat{y}_i}{y_i}\right|, \qquad \text{viés} = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i). \tag{2-1}$$

Como o MAPE é instável com y_i próximo de zero, ele é calculado só sobre os demais pontos, e a fração mantida (cobertura da máscara) é informada. As quatro primeiras métricas são simétricas, mas, na alocação, a superestimação gera custo e a subestimação gera violações, de modo que um modelo com menor RMSE não leva necessariamente às melhores decisões. Por isso são usados também o viés, cujo valor negativo indica tendência a subestimar a demanda, e a taxa de subestimação, que é a fração das previsões abaixo do valor real.

Métricas de alocação. Medem o resultado das decisões tomadas a partir da previsão. Para T intervalos:

$$
\begin{aligned}
C &= \sum_{t=1}^{T} c \cdot n_t, & V &= \frac{1}{T}\sum_{t=1}^{T} \mathbf{1}\left[\, d_t > k \cdot n_t \,\right], \\
U &= \frac{\sum_t \max(0,\, d_t - k \cdot n_t)}{\sum_t d_t}, & O &= \frac{\sum_t \max(0,\, k \cdot n_t - d_t)}{\sum_t k \cdot n_t}, \\
A &= \sum_{t=2}^{T} \mathbf{1}\left[\, n_t \neq n_{t-1} \,\right], & C_{\mathrm{norm}} &= \frac{C}{C_{\text{oráculo}}},
\end{aligned}
\tag{2-2}
$$

em que C é o custo total, V é a fração de intervalos com violação, U é a fração da demanda não atendida, O é a fração da capacidade ociosa e A é o número de alterações em n_t, indesejáveis na prática. U mede a magnitude das violações, que V apenas conta, e O mede a capacidade paga e não usada. C e V são, respectivamente, a função objetivo e o lado esquerdo da restrição da Equação 1-1. O custo é normalizado pelo de um oráculo, que conhece a demanda futura e aloca, em cada intervalo, o menor número de instâncias que a atende, $\lceil d_t/k \rceil$. Como nenhuma alocação mais barata atende toda a demanda, $C_{\text{oráculo}}$ é o piso do custo sem violações; uma política que viola pode custar menos que o oráculo, e por isso C_{norm} deve ser lido sempre junto com V.

2.2 Abordagens para previsão de carga

2.2.1 Modelos estatísticos

Os métodos mais simples de previsão servem como referência para todos os demais (HYNDMAN; ATHANASOPOULOS, 2018). O método ingênuo, ou de persistência, assume que o próximo valor será igual ao último observado, $\hat{y}_{t+1} = y_t$. A média móvel usa a média das w últimas observações. O sazonal ingênuo repete o valor observado um período sazonal antes, $\hat{y}_{t+h} = y_{t+h-s}$, em que s é o período da sazonalidade, medido em intervalos, e $h \leq s$. O método de Holt-Winters acrescenta à suavização exponencial componentes de tendência e de sazonalidade, o que o torna adequado aos ciclos diários comuns em cargas de nuvem (HYNDMAN; ATHANASOPOULOS, 2018). A família ARIMA (*AutoRegressive Integrated Moving Average*), sistematizada pela metodologia de Box e Jenkins (BOX

et al., 2015), aplica d diferenciações para tornar a série estacionária e descreve o resultado como combinação linear de p valores passados e de q erros de previsão passados; as ordens p, d e q podem ser escolhidas pela análise das funções de autocorrelação ou por critérios de informação, como o critério de informação de Akaike (AIC) (HYNDMAN; ATHANASOPOULOS, 2018).

Calheiros et al. (2015) aplicaram um ARIMA à demanda horária de requisições à Wikipédia e avaliaram no CloudSim (CALHEIROS et al., 2011) o efeito sobre a qualidade de serviço (QoS): provisionar pelos limites superiores dos intervalos de confiança, em vez do valor previsto, reduziu as violações de QoS ao custo de mais horas de máquina virtual, um ajuste aplicado depois da previsão que controla o equilíbrio entre custo e violações. A avaliação, contudo, envolve um único previsor.

Limitações. Os modelos estatísticos assumem relações lineares e, no ARIMA, estacionariedade após a diferenciação, hipóteses que as mudanças de regime e os picos das cargas de nuvem violam, e, em sua forma básica, são univariados. Por outro lado, exigem poucos dados, são baratos de ajustar e interpretáveis, e por isso devem estar em qualquer comparação: uma rede neural só se justifica se os superar sob as mesmas condições.

2.2.2 Redes neurais recorrentes

Para aplicar uma rede neural, a série é transformada em um problema supervisionado por janela deslizante, com as w observações mais recentes na entrada; para vários horizontes, a estratégia direta usa uma saída por horizonte, em vez de realimentar as próprias previsões e acumular erro (TAIEB et al., 2012). As redes neurais recorrentes (RNN) leem a janela em ordem e mantêm um estado interno que funciona como memória, mas têm dificuldade de aprender relações entre observações distantes (BENGIO; SIMARD; FRASCONI, 1994). A LSTM (*Long Short-Term Memory*) resolve esse problema com portas que aprendem o que guardar e o que esquecer (HOCHREITER; SCHMIDHUBER, 1997). A GRU (*Gated Recurrent Unit*) simplifica essa ideia com duas portas (CHO et al., 2014), sendo mais barata de treinar e com desempenho comparável (CHUNG et al., 2014). O esDNN (XU et al., 2022) combina uma GRU modificada com camadas convolucionais para prever processador e memória nos rastros da Alibaba e do Google; a GRU pura é competitiva em horizontes curtos, mas a avaliação da previsão usa apenas métricas de erro simétricas.

Limitações. Redes recorrentes exigem mais dados e mais ajuste do que os modelos estatísticos e, treinadas para minimizar um erro médio, tendem a suavizar os picos de demanda. Agulló López et al. (2025) mostram que previsores tradicionais e profundos falham justamente nesses picos, sem que as métricas usuais revelem a falha, e que ajustar a saída da previsão melhora a antecipação dos picos ao custo de mais superprovisionamento. Isso reforça que o erro médio não basta para avaliar um previsor usado na alocação.

2.2.3 Modelos com quantificação de incerteza

Rossi et al. (2025) propõem uma rede neural bayesiana (HBNN) e uma LSTM com saída distribucional (LSTMD), que preveem uma distribuição para a demanda de processador e de memória nos rastros do Google e da Alibaba, e mostram que métricas de erro pontual não distinguem bem os modelos, ao contrário de métricas de nível de serviço calculadas sobre o limite superior do intervalo de confiança: a taxa de sucesso, fração dos intervalos em que a demanda fica abaixo desse limite, e o total de recursos previstos, soma dos limites em relação à demanda. Os autores também concluem que a transferência de aprendizado funciona dentro de um mesmo provedor, mas se degrada entre provedores diferentes.

Limitações. Essas métricas são calculadas sobre a própria previsão, sem mecanismo de alocação, integração que os autores deixam como trabalho futuro, e supõem capacidade contínua, e não instâncias discretas com atraso de inicialização. Este trabalho mede diretamente as métricas de alocação e mantém a ideia de provisionar pelo limite superior na forma determinística da margem m (Seção 2.3.2).

2.3 Abordagens para alocação de recursos

2.3.1 Heurísticas e políticas reativas

As políticas baseadas em limiares são a forma mais difundida de escalonamento automático (LORIDO-BOTRAN; MIGUEL-ALONSO; LOZANO, 2014). Se a utilização média das instâncias permanece acima de um limiar superior por alguns intervalos, uma instância é adicionada, e, se permanece abaixo de um limiar inferior, uma é removida. Um período de espera (*cooldown*) após cada ação impede oscilações. O *Horizontal Pod Autoscaler* (HPA) do Kubernetes usa uma variação proporcional, que calcula o número de réplicas pela razão entre a métrica observada u_t e um valor-alvo u^* (THE KUBERNETES AUTHORS, 2024):

$$n_{t+1} = \left\lceil n_t \cdot \frac{u_t}{u^*} \right\rceil, \tag{2-3}$$

com uma faixa de tolerância, dentro da qual nenhuma ação é tomada, e uma janela de estabilização para reduções. O esDNN usa como referência outra política reativa, que mantém ativa a média do número de máquinas dos cinco intervalos anteriores (XU et al., 2022).

Limitações. Por construção, as políticas reativas só respondem depois da mudança de carga, defasagem que o atraso de inicialização aumenta. Os limiares precisam ser ajustados para cada aplicação: limiares agressivos causam oscilações, e conservadores mantêm capacidade ociosa. Ainda assim, por serem simples, previsíveis e amplamente usadas, a variante proporcional do HPA (Equação 2-3) é a referência reativa deste trabalho.

2.3.2
Alocação guiada por previsão

Na alocação guiada por previsão, a decisão tem duas etapas desacopladas: um modelo estima a demanda $\hat{d}_{t+h}$ do intervalo em que a decisão terá efeito, e uma regra converte essa estimativa em número de instâncias, normalmente dividindo-a pela capacidade de uma instância e acrescentando uma margem de segurança $m \geq 0$, com um piso de $n_{\min}$ instâncias:

$$n_{t+h} = \max\left(n_{\min},\ \left\lceil \frac{(1+m)\,\hat{d}_{t+h}}{k} \right\rceil\right). \tag{2-4}$$

Na alocação, t é a origem τ e o horizonte é a antecedência, $h = L$, para que a previsão se refira ao intervalo em que a decisão vale (Seção 2.1.3). Margens maiores reduzem V e aumentam C, e escolher a margem em um conjunto de validação é a forma prática de buscar o menor custo que respeita o limite ε da Equação 1-1. Com um modelo que fornece uma distribuição, a margem pode dar lugar a um quantil (ROSSI et al., 2025; CALHEIROS et al., 2015).

O MagicScaler (PAN et al., 2023) combina uma previsão com incerteza a uma otimização estocástica que minimiza o custo sujeito a um limite de demanda não atendida e, em *clusters* da Alibaba Cloud, reduziu a perda de qualidade de serviço em relação a uma política reativa, com pequeno aumento de custo. Seus dados, porém, são privados, e a decisão é aplicada apenas ao próprio previsor.

A principal vantagem do desacoplamento é a modularidade: com a regra de decisão fixa, é possível trocar apenas o previsor e atribuir a ele as diferenças de custo e de violações, propriedade que este trabalho explora.

2.3.3
Aprendizado por reforço

No aprendizado por reforço, um agente aprende uma política que mapeia o estado do sistema diretamente em ações, como adicionar ou remover instâncias, guiado por uma recompensa que penaliza custo e violações (LORIDO-BOTRAN; MIGUEL-ALONSO; LOZANO, 2014). Esses métodos são sensíveis ao projeto da recompensa e aos hiperparâmetros, enfrentam limitações de escalabilidade conforme o espaço de estados cresce (BODRA; KHAIRNAR, 2025) e exigem um ambiente de simulação e um grande número de episódios de treinamento. Além disso, uma política aprendida é difícil de interpretar: quando ela decide mal, não se sabe se o problema está na antecipação da demanda ou na decisão. Por isso, este trabalho adota a abordagem desacoplada e deixa a comparação com uma política aprendida para trabalhos futuros.

2.4
Comparativo dos trabalhos relacionados e lacuna

A Tabela 2.1 resume os trabalhos mais próximos desta proposta, indicando também se a previsão é acoplada a uma decisão de alocação e se diferentes

Tabela 2.1: Comparativo entre os trabalhos relacionados e a proposta deste trabalho.

Trabalho	**Técnica de previsão**	**Dados**	**Métricas**	**Acopla à alocação**	**Mesma política**
Calheiros et al. (2015)	ARIMA	Wikipédia (1 h)	Precisão, QoS e horas de máquina	Sim	Não
Xu et al. (2022)	GRU com convolução, multivariada	Alibaba e Google	Erro e máquinas ativas	Parcial	Não
Pan et al. (2023)	Atenção e processo gaussiano	Alibaba Cloud (privados)	Erro, custo e perda de QoS	Sim	Não
Rossi et al. (2025)	Bayesianas (HBNN, LSTMD)	Alibaba e Google	Erro e nível de serviço	Não	–
Agulló López et al. (2025)	Vários, com saída ajustada	Alibaba e Google	Erro, picos e super-provisionamento	Não	–
Bodra e Khairnar (2025)	Revisão de vários métodos	Variados	Heterogêneas	–	–
Este trabalho	GRU e cinco métodos tradicionais	Alibaba (PF I); Google (PF II)	Erro, custo e violações	Sim	Sim

Nota: o traço indica que o critério não se aplica.

previsores são comparados sob a mesma política. Esses trabalhos formam duas linhas que não se encontram. Os de previsão (XU et al., 2022; ROSSI et al., 2025; AGULLÓ LÓPEZ et al., 2025) comparam vários modelos por métricas calculadas sobre a própria previsão, que não indicam a utilidade dos modelos para a gestão de recursos (ROSSI et al., 2025) nem revelam as falhas nos picos (AGULLÓ LÓPEZ et al., 2025). Os que acoplam a previsão à alocação (CALHEIROS et al., 2015; PAN et al., 2023) aplicam a decisão a um único previsor, comparado com políticas reativas, e o esDNN compara sua simulação de escalonamento apenas com uma política baseada na média das observações anteriores (XU et al., 2022). A revisão de Bodra e Khairnar (2025) observa, por fim, que a literatura carece de comparações quantitativas sistemáticas.

A lacuna que este trabalho busca preencher, até onde se verificou nos trabalhos revisados, é, portanto, a de uma avaliação de ponta a ponta, com dados públicos de um *cluster* real, que submeta previsores de complexidade crescente, do método ingênuo à rede neural, à mesma política de alocação, calibrada para o mesmo limite de violações ε, e meça o custo e as violações resultantes. A pergunta deixa de ser qual modelo erra menos e passa a ser quanto custo cada modelo economiza para um mesmo nível de serviço.

2.5 Tecnologias utilizadas

O protótipo é escrito em Python 3.12, pela disponibilidade de bibliotecas para séries temporais e aprendizado profundo, e o código está em repositório público (ROSAS, 2026). A Tabela 2.2 relaciona as ferramentas usadas em cada etapa do *pipeline*.

Tabela 2.2: Ferramentas utilizadas em cada etapa do *pipeline*.

Etapa	**Ferramenta**	**Uso no trabalho**
Dados	DuckDB (RAASVELDT; MÜHLEISEN, 2019)	Agregação do rastro bruto (1,7 GB compactado) por consultas SQL, sem carregá-lo inteiro na memória
	Parquet, pandas (MCKINNEY, 2010) e NumPy (HARRIS et al., 2020)	Armazenamento e manipulação das séries; previsores ingênuo, média móvel e sazonal ingênuo
Previsão	statsmodels (SEABOLD; PERKTOLD, 2010); PyTorch (PASZKE et al., 2019) para CPU	ARIMA e Holt-Winters; GRU, sem exigir GPU
Simulação	Python; CloudSim Plus (FILHO et al., 2017) como validação opcional (PF II)	Alocação intervalo a intervalo e métricas
Resultados	Matplotlib (HUNTER, 2007)	Figuras
Ambiente	uv, Docker, Makefile, pytest, Git e GitHub	Dependências travadas, contêiner, encadeamento das etapas, testes e versionamento

O CloudSim (CALHEIROS et al., 2011) é um simulador, em Java, de eventos discretos que modela centros de dados, servidores, máquinas virtuais e a execução de tarefas, usado, por exemplo, na avaliação do provisionamento guiado por ARIMA de Calheiros et al. (2015). Para a reprodutibilidade, as versões das dependências ficam travadas, todos os parâmetros dos experimentos ficam em um arquivo de configuração, e nenhum no código, e um único comando regenera todas as tabelas e figuras a partir dos dados brutos.

3
Objetivos do trabalho

Este capítulo descreve a solução proposta para a lacuna da Seção 2.4, os objetivos, o escopo e o público do sistema e os itens a apresentar à banca.

3.1
Solução proposta

A solução proposta é um arcabouço de alocação preditiva construído para responder quanto custo operacional uma previsão de carga melhor permite economizar, para um mesmo nível de serviço. Ele segue a abordagem desacoplada da Seção 2.3.2, com os quatro componentes da Figura 3.1.

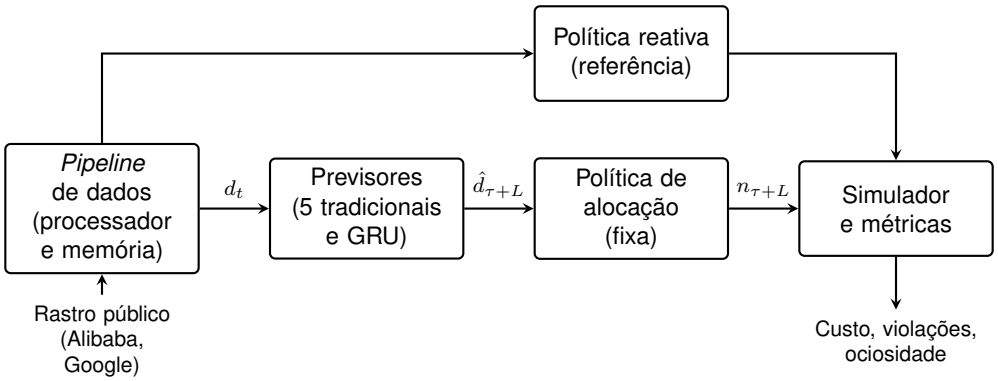


Figura 3.1: Arquitetura da solução proposta.

***Pipeline* de dados.** Converte um rastro público de *cluster* em séries de demanda de processador e de memória com intervalos de cinco minutos, expressas em máquinas equivalentes totalmente utilizadas.

Previsores. Os cinco métodos tradicionais da Seção 2.2.1 e uma GRU que, a partir das últimas seis horas, prevê todos os horizontes de uma vez (estratégia direta), com uma interface comum que só dá acesso ao histórico até a origem τ. A parada antecipada (*early stopping*) da GRU usa o fim do treino, e não a validação, que serve apenas à escolha dos parâmetros das políticas.

Política de alocação. Aplica a margem m sobre a demanda prevista com $h = L$ (Equação 2-4). As referências são a política reativa do HPA (Equação 2-3), o dimensionamento estático, com o número de instâncias necessário no pico do treino, e o oráculo (Seção 2.1.4).

O parâmetro de cada política é escolhido no conjunto de validação e avaliado no conjunto de teste. Para um limite de violações ε, a margem escolhida é a de menor custo, na grade da Tabela 3.3, entre as que cumprem o limite na validação:

$$m^*(\varepsilon) = \arg\min_{m} \; C_{\mathrm{val}}(m) \quad \text{sujeito a} \quad V_{\mathrm{val}}(m) \leq \varepsilon, \tag{3-1}$$

em que C_{val} e V_{val} são o custo e a fração de intervalos com violação na validação. O **ponto de operação** de um previsor para o limite ε é a política preditiva com a

margem $m^*(\varepsilon)$, medida no teste. Na política reativa, a escolha é a mesma, com a utilização-alvo u^* no lugar de m; o dimensionamento estático e o oráculo são usados sem margem. Se nenhum valor da grade cumpre o limite na validação, a política não tem ponto de operação para aquele ε. Essa é a versão operacional da Equação 1-1: como a restrição é verificada na validação, o teste nunca participa da escolha, e o ponto de operação pode ultrapassar ε no teste.

Simulador e métricas. Reproduz, intervalo a intervalo, a alocação de instâncias homogêneas, em que a decisão tomada em τ vale em $\tau + L$, e calcula as métricas da Seção 2.1.4. É implementado em Python nos Projetos Finais I e II; se o cronograma permitir, um subconjunto dos experimentos será reproduzido no CloudSim Plus (FILHO et al., 2017) como validação.

A decisão metodológica central é manter a política de alocação **fixa** e variar apenas o previsor. Assim, qualquer diferença de custo ou de violações entre duas configurações pode ser atribuída à previsão, e não à regra de decisão.

3.2 Objetivos

3.2.1 Objetivo geral

Avaliar, em um ambiente de simulação alimentado por rastros públicos, a redução de custo obtida pela alocação guiada por uma rede neural recorrente, em comparação com métodos tradicionais sob a mesma política e com uma política reativa, para limites fixos de violação de SLA.

3.2.2 Questões de pesquisa

O objetivo geral se desdobra nas cinco questões de pesquisa (QP) da Tabela 3.1.

Tabela 3.1: Questões de pesquisa.

QP	Questão
QP1	Para um mesmo limite de violações ε, a alocação guiada pela rede neural tem custo menor do que a guiada pelos métodos tradicionais? De quanto é a diferença?
QP2	Um previsor com menor erro (RMSE, MAE) leva necessariamente a uma alocação mais barata no ponto de operação?
QP3	Qual é o ganho da alocação preditiva em relação à reativa, e como ele varia com a antecedência da decisão L?
QP4	As conclusões obtidas no rastro da Alibaba se mantêm no rastro do Google?
QP5	Incluir a memória como entrada da GRU reduz o custo de alocação em relação à GRU univariada, para o mesmo ε?

3.2.3 Objetivos específicos

A Tabela 3.2 lista os objetivos específicos (OE), as questões de pesquisa a que respondem e a situação de cada um ao fim do Projeto Final I.

Tabela 3.2: Objetivos específicos, questões de pesquisa associadas e situação ao fim do Projeto Final I.

OE	Descrição	QP	Situação no PF I
OE1	**Dados:** agregar o rastro da Alibaba de 2018 em séries de 5 min, com lacunas tratadas e relatório de qualidade	–	Implementado
OE2	**Previsores:** implementar os seis previsores e avaliar seu erro em cada horizonte	–	Implementado
OE3	**Simulador e políticas:** implementar e testar o simulador e as políticas da Seção 3.1	–	Protótipo em Python implementado
OE4	**Memória:** incluir a memória como segundo recurso na alocação, com n_t dado pelo maior entre os necessários para processador e para memória, e como entrada da GRU, comparada à GRU univariada	QP5	Previsto para o PF II
OE5	**Custo e violações:** pontos de operação para $\varepsilon = 1\%$ e 5% e curvas de custo contra violações	QP1, QP3	Preliminar
OE6	**Erro e custo:** confrontar o erro com $h = L$ e o custo no ponto de operação	QP2	Preliminar
OE7	**Sensibilidade:** efeito da antecedência L sobre os pontos de operação	QP3	Parcial ($L = 1$ e $L = 2$)
OE8	**Robustez:** várias sementes da GRU e várias janelas de teste, com média e dispersão	–	Previsto para o PF II
OE9	**Replicação:** mesmo protocolo no rastro do Google de 2019, mudando só a leitura dos dados	QP4	Previsto para o PF II
OE10	**Reprodutibilidade:** repositório público que regenera tabelas e figuras com um comando	–	Implementado; a ser mantido

Os resultados preliminares do Projeto Final I usam uma janela de teste e uma semente da GRU. No Projeto Final II, cada rastro é avaliado em janelas de teste com treino expansivo e validação do mesmo tamanho do teste: três janelas de um dia (288 intervalos) na Alibaba, com teste nos dias 5, 6 e 7 e treino de 0 a 3, 0 a 4 e 0 a 5, e de três a quatro janelas de dois a três dias por célula no Google, com pelo menos 14 dias de treino. A GRU é treinada com dez sementes (42 a 51), cada uma com o ponto de operação escolhido na validação e medido no teste, e entra na comparação pela média entre sementes; os demais previsores rodam uma vez por janela.

O melhor previsor em ε é o de menor C_{norm} médio entre os que têm V médio de no máximo ε. Afirmar que um previsor é melhor que outro exige que o intervalo de 95% da diferença pareada de C_{norm}, obtido por *bootstrap* (EFRON; TIBSHIRANI, 1993), exclua zero, com correção de Holm (HOLM, 1979) nas comparações pré-especificadas; na Alibaba, com três janelas, a conclusão é

apenas descritiva. O erro de previsão é comparado à parte, pelo teste de Diebold-Mariano (DIEBOLD; MARIANO, 1995).

3.3 Escopo do sistema

O sistema é um **ambiente de simulação e avaliação**, e não um autoescalador para produção: recebe um rastro e um arquivo de configuração e produz as métricas de previsão e de alocação. A Tabela 3.3 resume os parâmetros da alocação e da avaliação, e a Tabela B.1, no Apêndice B, os dos previsores e as janelas e sementes do Projeto Final II. Os parâmetros do protótipo são mantidos no Projeto Final II, salvo os ajustes de OE7 a OE9 e as janelas e sementes da Seção 3.2.3.

Tabela 3.3: Parâmetros da alocação e do protocolo de avaliação.

Parâmetro	**Símbolo**	**Valor**
Intervalo de agregação	Δ	5 minutos
Divisão treino/validação/teste (PF I)	–	60% / 20% / 20%, cronológica
Horizontes de previsão avaliados	h	1, 2, 3 e 6 intervalos (5 a 30 min)
Antecedência da decisão	L	1 intervalo; 2 na análise de sensibilidade
Instâncias no pico do treino	n_{pico}	50
Capacidade de uma instância	k	Pico do treino dividido por n_{pico} (60,94 máquinas equivalentes)
Custo por instância e intervalo	c	1
Número mínimo de instâncias	$n_{\min}$	1
Grade de margens (preditiva)	m	0 a 0,60, com passo 0,01
Grade de utilizações-alvo (reativa)	u^*	0,50 a 0,99, com passo 0,01
Tolerância e estabilização (reativa)	–	10% e 6 intervalos
Limites de violação	ε	1% e 5%

Valem as simplificações do Capítulo 2: demanda agregada, instâncias homogêneas e violação sempre que a demanda de um intervalo excede a capacidade. No protótipo, a alocação considera apenas o processador, e a GRU é univariada. No Projeto Final II, a memória entra de duas formas: como segundo recurso na alocação, com o número de instâncias dado pelo maior entre os necessários para processador e para memória, e como entrada adicional da GRU, nos moldes do esDNN (XU et al., 2022). Os itens fora do escopo são os da Seção 1.4.

3.4 Usuários e situações apoiadas

O ambiente se destina a pesquisadores e a engenheiros de planejamento de capacidade, para comparar previsores sob um mesmo limite de violações, estimar o custo de um nível de serviço e estender a avaliação a novos previsores, políticas ou rastros.

3.5 Avanços em relação às soluções existentes

Sem propor uma nova arquitetura, já que a GRU é deliberadamente simples, o trabalho busca, em relação à lacuna da Seção 2.4:

- **Comparação controlada:** do ingênuo à rede neural, sob a mesma política.
- **Custo a um mesmo nível de serviço:** instâncias discretas e antecedência.
- **Erro contra custo:** a QP2 testa se menor erro implica menor custo.

3.6 Itens a serem implementados e apresentados à banca

Os itens a implementar são os da Tabela 3.2, mais o relatório final e a apresentação. Na defesa, serão apresentados: (i) as curvas de custo contra violações e os pontos de operação de todos os previsores e da política reativa, nos dois rastros; (ii) a comparação entre a ordenação dos previsores por erro e por custo; (iii) a análise de sensibilidade à antecedência da decisão L; e (iv) a regeneração dos resultados a partir dos dados brutos pelo repositório.

Se o cronograma permitir, a margem fixa poderá ser trocada por um quantil previsto pela rede (ROSSI et al., 2025; PAN et al., 2023).

4
Revisão do Plano de Ação

Este capítulo compara o plano do Projeto Final I com o que foi realizado, discute as mudanças de plano e as dificuldades, apresenta os resultados preliminares do protótipo e lista as pendências para o Projeto Final II.

4.1
Plano previsto

A proposta do trabalho previa avaliar a alocação preditiva com os rastros públicos da Alibaba (ALIBABA GROUP, 2018) e do Google (WILKES, 2020), em um centro de dados simulado no CloudSim Plus (FILHO et al., 2017), comparando uma rede neural com métodos tradicionais de previsão e com uma política reativa (Seção 1.4). Para o Projeto Final I, a meta foi um protótipo de ponta a ponta que servisse de evidência de viabilidade: partir do rastro bruto da Alibaba e chegar às curvas de custo contra violações, primeiro com previsores tradicionais e, na etapa seguinte, com a rede neural. A construção foi dividida em fases curtas, cada uma com uma especificação, um critério de aceite e uma duração reservada, e com pontos de verificação ao fim das fases de ambiente, dados, simulador e experimento. As fases, a duração prevista e as datas de conclusão estão na Tabela 5.1; a entrega do protótipo estava prevista para 31/10/2026.

4.2
Atividades realizadas

Todas as fases foram concluídas dentro do prazo, as datas vêm do histórico de versões do repositório (ROSAS, 2026), e a situação de cada objetivo específico está na Tabela 3.2.

A tabela de uso por máquina do rastro da Alibaba, com 246.934.820 linhas, foi agregada em uma série de 2.304 intervalos de cinco minutos, que cobre os oito dias do rastro e as $M = 4.023$ máquinas. A Figura 4.1 mostra a série com a divisão cronológica, o trecho preenchido, em tracejado, e, no painel inferior, a cobertura, isto é, a fração das M máquinas que enviaram medições em cada intervalo; abaixo da linha pontilhada, o intervalo é tratado como lacuna. Na validação e no teste, a cobertura é de pelo menos 97,8% em todos os intervalos; no treino, que contém o início do rastro, a média é de 88,6% e a mínima, fora das lacunas, incluindo a do apagão, de 53,7%. A divisão cronológica resultou em 1.382 intervalos de treino, 460 de validação e 462 de teste.

Os previsores foram avaliados com origem móvel (*walk-forward*), com 460 origens na validação e 462 no teste, e testes automatizados verificam que alterar os dados posteriores à origem não muda nenhuma previsão. O simulador tem testes de casos calculados à mão e verificações de sanidade, como a de que

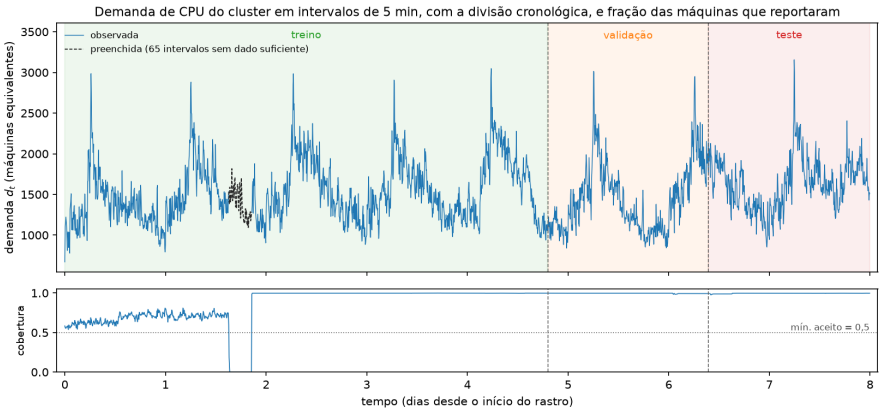


Figura 4.1: Demanda de processador e cobertura do rastro da Alibaba.

o oráculo não viola nenhum intervalo, e duas execuções completas do *pipeline* produzem arquivos idênticos byte a byte.

4.3 Dificuldades encontradas

Holt-Winters. O statsmodels não aplica os parâmetros estimados a dados novos, e reajustar o modelo em cada uma das centenas de origens seria lento demais. A recursão do método foi implementada no próprio previsor, com os parâmetros estimados no treino, e um teste automatizado confirma que ela reproduz a biblioteca até a precisão de máquina.

Ponto flutuante. Três problemas tiveram origem no ponto flutuante: o oráculo aparecia com violações inexistentes, porque $k \cdot \lceil d_t/k \rceil$ pode ficar ligeiramente abaixo de d_t; o arredondamento para cima do número de instâncias saltava para o inteiro seguinte quando o valor exato era inteiro; e a soma paralela do DuckDB variava na última casa decimal entre execuções. As comparações e os arredondamentos passaram a usar uma tolerância relativa de 10^{-9}, e a série passou a ser gravada com seis casas decimais.

Tamanho do teste. Com 462 intervalos, um intervalo com violação vale 0,22 ponto percentual de V, e a diferença entre cumprir ou não $\varepsilon = 1\%$ no teste é de um único intervalo. O uso do rastro completo aumentou o teste, mas não mudou a ordem de grandeza do problema, o que motiva a avaliação com várias janelas de teste (OE8).

4.4 Resultados preliminares

Os resultados desta seção vêm do protótipo, com o rastro da Alibaba e os parâmetros da Tabela 3.3. Os parâmetros das políticas foram escolhidos na validação (Equação 3-1) e medidos no teste, que não participa de nenhuma escolha. Os resultados são preliminares porque usam uma única janela de teste e uma única semente de treinamento da GRU: com eles, diferenças de custo de

poucos por cento entre previsores, como as observadas, não permitem afirmar que um é melhor que outro.

A Tabela 4.1 mostra o erro das previsões no teste para o horizonte usado na alocação, $h = L = 1$, com RMSE, MAE e viés em máquinas equivalentes e viés positivo indicando superestimação. O ARIMA tem o menor erro, seguido da GRU, com RMSE 3,1% maior. Os vieses do ARIMA, do Holt-Winters, do ingênuo e da média móvel são pequenos perto do RMSE, enquanto a GRU superestima a demanda em média, com viés de $+17{,}59$. O sazonal ingênuo é o pior por larga margem, porque repete o valor de um dia antes e não acompanha as variações de curto prazo. O erro nos horizontes $h = 2$, 3 e 6, na validação e no teste, está no Apêndice A.

Tabela 4.1: Erro das previsões no teste com $h = 1$.

Previsor	**RMSE**	**MAE**	**Viés**	**Taxa de subestimação**
ARIMA	157,44	120,25	$+1{,}75$	42,9%
GRU	162,26	125,56	$+17{,}59$	39,4%
Ingênuo	168,05	126,83	$+0{,}56$	45,0%
Holt-Winters	173,68	133,44	$-1{,}13$	51,5%
Média móvel	187,65	142,68	$+3{,}01$	46,5%
Sazonal ingênuo	360,90	291,42	$-166{,}41$	66,9%

A Figura 4.2 mostra as curvas de custo contra violações no teste. Cada curva varia o parâmetro de uma política, m na preditiva e u^* na reativa; as linhas verticais marcam $\varepsilon = 1\%$ e 5%, o eixo horizontal é linear até 1% e logarítmico a partir daí, e, na legenda, *naive* designa o método ingênuo. A Tabela 4.2 traz os pontos de operação de cada política. Cinco observações se destacam.

Tabela 4.2: Pontos de operação no teste, com $L = 1$ e $L = 2$.

	$\varepsilon = 1\%$					$\varepsilon = 5\%$				
	$L = 1$			$L = 2$		$L = 1$			$L = 2$	
Política	**Par.**	C_{norm}	V (%)	C_{norm}	V (%)	**Par.**	C_{norm}	V (%)	C_{norm}	V (%)
Oráculo	–	1,000	0,00	1,000	0,00	–	1,000	0,00	1,000	0,00
Dimensionamento estático	–	1,830	0,22	1,830	0,22	–	1,830	0,22	1,830	0,22
Reativa (HPA)	0,82	1,340	**1,08**	1,376	0,65	0,92	1,197	4,98	1,223	4,98
Preditiva com:										
ARIMA	0,32	1,315	0,87	1,385	0,65	0,18	1,176	3,90	1,238	3,25
GRU	0,28	1,287	0,87	1,356	0,43	0,19	1,199	3,25	1,226	3,68
Holt-Winters	0,40	1,391	0,43	1,440	0,87	0,19	1,185	3,46	1,233	3,03
Ingênuo	0,38	1,373	0,87	1,412	0,65	0,21	1,206	3,46	1,275	3,90
Média móvel	0,36	1,354	0,43	1,434	0,43	0,24	1,238	3,90	1,238	3,90
Sazonal ingênuo	0,42	1,270	**13,64**	1,270	**13,64**	0,23	1,103	**33,55**	1,103	**33,55**

Nota: Par. é a margem m na política preditiva e a utilização-alvo u^* na reativa, escolhida na validação (Equação 3-1) com $L = 1$; com $L = 2$, a escolha é refeita da mesma forma. Valores de V em negrito ultrapassam ε no teste.

Ajustar a capacidade à demanda reduz muito o custo em relação ao dimensionamento estático, mas a previsão pouco se distingue da política reativa. Em $\varepsilon = 5\%$, as políticas que cumprem o limite no teste, preditivas ou reativa, ficam de 32,4% a 35,7% abaixo do dimensionamento estático, e a reativa,

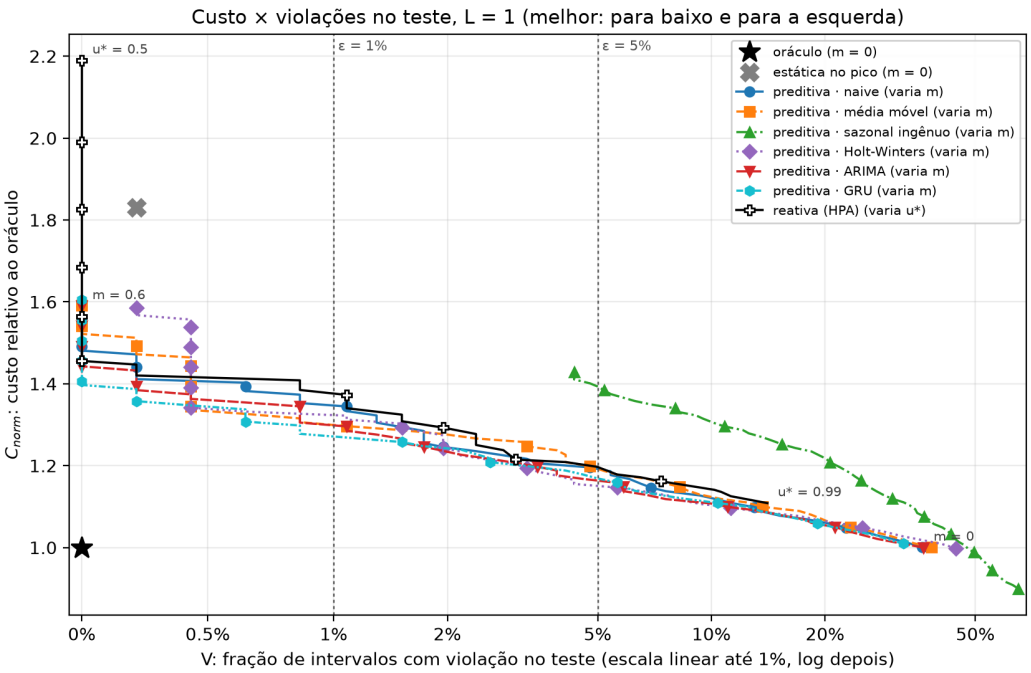


Figura 4.2: Custo normalizado contra fração de intervalos com violação no teste, com $L = 1$.

34,6% abaixo; esse ganho vem da elasticidade, e não da previsão. Contra a reativa, só o ARIMA, 1,7% mais barato, e o Holt-Winters ficam abaixo. Em $\varepsilon = 1\%$, a GRU é a mais barata entre as que cumprem o limite, 3,9% abaixo da reativa, que o ultrapassa no teste. A GRU e o ARIMA trocam de posição entre os dois limites, com diferença em torno de 2%, sem vantagem clara de nenhum dos dois. A Tabela 4.3 mostra a origem do custo: pelas definições da Equação 2-2, $C_{\text{norm}} = (1 - U)(1 - O_{\text{oráculo}})/(1 - O)$, e, como U fica abaixo de 0,4% em todas as políticas, exceto o sazonal ingênuo, o custo acima do oráculo é quase todo capacidade ociosa. Em $\varepsilon = 5\%$, O vai de 1,89% no oráculo, que só perde o arredondamento de $\lceil d_t/k \rceil$, a 16,84%–20,92% nas políticas que cumprem o limite e a 46,41% no dimensionamento estático.

Menor erro de previsão não garante menor custo. O Holt-Winters tem o quarto menor RMSE, mas, em $\varepsilon = 1\%$, é o previsor mais caro entre os que cumprem o limite no teste, acima da média móvel, cujo RMSE é 8% maior; em $\varepsilon = 5\%$, ao contrário, é o segundo mais barato, à frente da GRU e do ingênuo, que têm RMSE menor. Em $\varepsilon = 1\%$, parte do custo maior compra menos violações, com $V = 0{,}43\%$ contra 0,87%, uma diferença de dois intervalos do teste, e por isso o resultado é um indício para a QP2, e não uma conclusão. Uma hipótese a testar no Projeto Final II é que o que pesa na alocação é o erro nas subidas da demanda, e não o erro médio.

A calibração na validação falha quando a demanda muda de comportamento entre os conjuntos. O sazonal ingênuo, de pior erro, tem o menor custo nos dois limites só porque viola em 13,6% e 33,5% dos intervalos do teste. Seu

Tabela 4.3: Demanda não atendida, capacidade ociosa e alterações no teste, com $L = 1$.

	$\varepsilon = 1\%$			$\varepsilon = 5\%$		
Política	U (%)	O (%)	A	U (%)	O (%)	A
Oráculo	0,00	1,89	378	0,00	1,89	378
Dimensionamento estático	0,01	46,41	0	0,01	46,41	0
Reativa (HPA)	0,06	26,84	116	0,39	18,37	116
Preditiva com:						
ARIMA	0,04	25,40	386	0,29	16,84	379
GRU	0,06	23,83	345	0,24	18,37	326
Holt-Winters	0,07	29,50	409	0,31	17,49	411
Ingênuo	0,02	28,57	403	0,25	18,82	397
Média móvel	0,06	27,60	284	0,26	20,92	282
Sazonal ingênuo	1,22	23,66	408	4,34	14,89	398

Nota: valores nos pontos de operação da Tabela 4.2; o oráculo e o dimensionamento estático não dependem de ε.

viés com $h = 1$ passa de $+96{,}08$ na validação, em que a demanda cai em relação ao dia anterior, para $-166{,}41$ no teste, em que ela sobe, e a margem escolhida na validação deixa de cobrir a subestimação. Com a reativa em $\varepsilon = 1\%$, que passa do limite por um intervalo, são três, entre os 16 pontos de operação fora o oráculo, os que ultrapassam ε no teste com $L = 1$. Calibrar em uma única janela supõe que o erro tem a mesma distribuição na validação e no teste, o que motiva a avaliação com várias janelas (OE8).

A política reativa muda de tamanho com muito menos frequência. Nos pontos de operação, ela altera o número de instâncias 116 vezes no teste (Tabela 4.3), contra 282 a 411 vezes das políticas preditivas. Como o modelo de custo não cobra pelas alterações, essa vantagem da reativa não aparece em C.

Com $L = 2$, a vantagem da previsão sobre a política reativa diminui. O custo no ponto de operação sobe em todas as políticas que dependem da demanda recente (Tabela 4.2). Em $\varepsilon = 1\%$, só a GRU fica abaixo da reativa, 1,5% a menos; em $\varepsilon = 5\%$, a reativa fica abaixo de todas as preditivas que cumprem o limite no teste. O sazonal ingênuo não muda, porque sua previsão não depende do horizonte.

5
Cronogramas

Nas duas tabelas, as células marcam os meses de cada atividade, e a coluna **OE** a relaciona aos objetivos da Tabela 3.2.

5.1
Projeto Final I

O Projeto Final I ocupou de agosto a novembro de 2026 (Tabela 5.1): agosto e setembro foram dedicados à escolha do tema, aos estudos e à proposta, e outubro, à construção e à avaliação do protótipo.

Tabela 5.1: Cronograma previsto e realizado do Projeto Final I, em 2026.

Atividade	OE	Ago	Set	Out	Nov	Concluído
Escolha do tema e da pergunta	–					–
Revisão bibliográfica	–					–
Elaboração da proposta	–					–
Ambiente e repositório	OE10					02/10
Tratamento dos dados	OE1					07/10
Previsores tradicionais	OE2					12/10
Simulador e políticas	OE3					22/10
Experimentos preliminares	OE5 a OE7					22/10
Rede neural (GRU)	OE2					25/10
Redação do relatório	–					–
Entrega do relatório	–					22/11

5.2
Projeto Final II

O Projeto Final II vai de dezembro de 2026 à defesa, no fim de junho de 2027 (Tabela 5.2), e começa pela memória, de que dependem todos os resultados finais.

Tabela 5.2: Cronograma proposto para o Projeto Final II.

		2026	2027					
Atividade	**OE**	**Dez**	**Jan**	**Fev**	**Mar**	**Abr**	**Mai**	**Jun**
Incorporação da memória	OE4							
Replicação no rastro do Google	OE9							
Várias sementes e janelas de teste	OE8							
Experimentos finais	OE5, OE6							
Sensibilidade à antecedência L	OE7							
Opcional: quantil previsto pela rede	–							
Opcional: validação no CloudSim Plus	–							
Manutenção do repositório	OE10							
Redação do relatório final	–							
Apresentação e defesa	–							

Referências

AGULLÓ LÓPEZ, F. et al. Enhancing the output of time series forecasting algorithms for cloud resource provisioning. **Future Generation Computer Systems**, v. 170, p. 107833, 2025.

ALIBABA GROUP. **Alibaba Cluster Trace Program**. 2018. Disponível em: https://github.com/alibaba/clusterdata. Acesso em: 14 out. 2026.

AMAZON WEB SERVICES. **Predictive scaling for Amazon EC2 Auto Scaling**. 2024. Documentação do Amazon EC2 Auto Scaling. Disponível em: https://docs.aws.amazon.com/autoscaling/ec2/userguide/ec2-auto-scaling-predictive-scaling.html. Acesso em: 14 out. 2026.

BELOGLAZOV, A.; BUYYA, R. Optimal online deterministic algorithms and adaptive heuristics for energy and performance efficient dynamic consolidation of virtual machines in cloud data centers. **Concurrency and Computation: Practice and Experience**, v. 24, n. 13, p. 1397–1420, 2012.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157–166, 1994.

BEYER, B. et al. **Site Reliability Engineering: How Google Runs Production Systems**. Sebastopol, CA: O'Reilly Media, 2016.

BODRA, D.; KHAIRNAR, S. Machine learning-based cloud resource allocation algorithms: a comprehensive comparative review. **Frontiers in Computer Science**, v. 7, p. 1678976, 2025.

BOX, G. E. P. et al. **Time Series Analysis: Forecasting and Control**. 5. ed. Hoboken, NJ: John Wiley & Sons, 2015.

CALHEIROS, R. N. et al. Workload prediction using ARIMA model and its impact on cloud applications' QoS. **IEEE Transactions on Cloud Computing**, v. 3, n. 4, p. 449–458, 2015.

CALHEIROS, R. N. et al. CloudSim: a toolkit for modeling and simulation of cloud computing environments and evaluation of resource provisioning algorithms. **Software: Practice and Experience**, v. 41, n. 1, p. 23–50, 2011.

CHO, K. et al. Learning phrase representations using RNN encoder–decoder for statistical machine translation. In: **Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)**. [S.l.: s.n.], 2014. p. 1724–1734.

CHUNG, J. et al. Empirical evaluation of gated recurrent neural networks on sequence modeling. In: **NIPS 2014 Workshop on Deep Learning**. [S.l.: s.n.], 2014. Disponível em: https://arxiv.org/abs/1412.3555. Acesso em: 14 out. 2026.

DIEBOLD, F. X.; MARIANO, R. S. Comparing predictive accuracy. **Journal of Business & Economic Statistics**, v. 13, n. 3, p. 253–263, 1995.

EFRON, B.; TIBSHIRANI, R. J. **An Introduction to the Bootstrap**. [S.l.]: Chapman & Hall, 1993.

FILHO, M. C. S. et al. CloudSim Plus: a cloud computing simulation framework pursuing software engineering principles for improved modularity, extensibility and correctness. In: **2017 IFIP/IEEE Symposium on Integrated Network and Service Management (IM)**. [S.l.: s.n.], 2017. p. 400–406.

HARRIS, C. R. et al. Array programming with NumPy. **Nature**, v. 585, p. 357–362, 2020.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997.

HOLM, S. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, v. 6, p. 65–70, 1979.

HUNTER, J. D. Matplotlib: A 2D graphics environment. **Computing in Science & Engineering**, v. 9, n. 3, p. 90–95, 2007.

HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting: principles and practice**. 2. ed. Melbourne: OTexts, 2018. Disponível em: https://otexts.com/fpp2/. Acesso em: 14 out. 2026.

LORIDO-BOTRAN, T.; MIGUEL-ALONSO, J.; LOZANO, J. A. A review of auto-scaling techniques for elastic applications in cloud environments. **Journal of Grid Computing**, v. 12, n. 4, p. 559–592, 2014.

MAO, M.; HUMPHREY, M. A performance study on the VM startup time in the cloud. In: **2012 IEEE Fifth International Conference on Cloud Computing (CLOUD)**. [S.l.: s.n.], 2012. p. 423–430.

MCKINNEY, W. Data structures for statistical computing in Python. In: WALT, S. van der; MILLMAN, J. (Ed.). **Proceedings of the 9th Python in Science Conference**. [S.l.: s.n.], 2010. p. 56–61.

MELL, P.; GRANCE, T. **The NIST Definition of Cloud Computing**. Gaithersburg, MD: National Institute of Standards and Technology, 2011. (NIST Special Publication, 800-145).

PAN, Z. et al. MagicScaler: Uncertainty-aware, predictive autoscaling. **Proceedings of the VLDB Endowment**, v. 16, n. 12, p. 3808–3821, 2023.

PASZKE, A. et al. PyTorch: An imperative style, high-performance deep learning library. In: **Advances in Neural Information Processing Systems 32 (NeurIPS 2019)**. [S.l.: s.n.], 2019.

RAASVELDT, M.; MÜHLEISEN, H. DuckDB: an embeddable analytical database. In: **Proceedings of the 2019 International Conference on Management of Data (SIGMOD '19)**. [S.l.]: ACM, 2019. p. 1981–1984.

ROSAS, G. L. d. S. **predictive-cloud-autoscaling: código do Projeto Final**. 2026. Disponível em: https://github.com/gabriellsar/predictive-cloud-autoscaling. Acesso em: 20 out. 2026.

ROSSI, A. et al. Forecasting workload in cloud computing: towards uncertainty-aware predictions and transfer learning. **Cluster Computing**, v. 28, n. 4, p. 258, 2025. Código e dados disponíveis em: https://github.com/andreareds/TowardsUncertaintyAwareWorkloadPrediction. Acesso em: 14 out. 2026.

SEABOLD, S.; PERKTOLD, J. statsmodels: Econometric and statistical modeling with Python. In: **Proceedings of the 9th Python in Science Conference**. [S.l.: s.n.], 2010.

TAIEB, S. B. et al. A review and comparison of strategies for multi-step ahead time series forecasting based on the NN5 forecasting competition. **Expert Systems with Applications**, v. 39, n. 8, p. 7067–7083, 2012.

THE KUBERNETES AUTHORS. **Horizontal Pod Autoscaling**. 2024. Documentação do Kubernetes. Disponível em: https://kubernetes.io/docs/concepts/workloads/autoscaling/horizontal-pod-autoscale/. Acesso em: 14 out. 2026.

WILKES, J. **Google cluster-usage traces v3**. Mountain View, CA, USA, 2020. Disponível em: https://github.com/google/cluster-data. Acesso em: 14 out. 2026.

XU, M. et al. esDNN: Deep neural network based multivariate workload prediction in cloud computing environments. **ACM Transactions on Internet Technology**, v. 22, n. 3, p. 75:1–75:24, 2022.

A
Erro de previsão por horizonte

As Tabelas A.1 e A.2 complementam a Tabela 4.1 com o erro dos seis previsores nos horizontes $h = 1$, 2, 3 e 6 (OE2), na validação e no teste. As tabelas são geradas pelo pipeline a partir de `results/tables/forecast_metrics.csv`.

Tabela A.1: Erro das previsões na validação, por horizonte h.

Previsor	h	RMSE	MAE	MAPE (%)	Viés	Taxa de subestimação
ARIMA	1	164,10	122,91	8,35	$-4{,}51$	47,4%
	2	199,70	146,58	9,87	$-8{,}04$	47,0%
	3	216,01	158,14	10,58	$-10{,}65$	48,0%
	6	245,61	174,89	11,62	$-16{,}76$	49,4%
GRU	1	167,32	126,06	8,77	$+10{,}11$	39,6%
	2	198,43	150,03	10,44	$+8{,}66$	40,0%
	3	213,01	160,85	11,22	$+10{,}21$	40,0%
	6	239,02	177,00	12,35	$+2{,}38$	42,4%
Ingênuo	1	174,68	131,38	8,97	$-1{,}38$	48,3%
	2	219,60	162,99	10,99	$-3{,}29$	47,8%
	3	238,43	174,84	11,72	$-5{,}30$	49,6%
	6	270,07	188,58	12,63	$-11{,}72$	50,4%
Holt-Winters	1	178,97	132,96	9,19	$+0{,}72$	51,1%
	2	220,68	161,36	11,16	$+1{,}06$	50,9%
	3	236,05	172,30	11,96	$+1{,}73$	51,3%
	6	235,93	177,68	12,42	$+3{,}92$	51,3%
Média móvel	1	194,53	142,77	9,62	$-6{,}29$	48,9%
	2	213,92	156,22	10,49	$-8{,}22$	49,4%
	3	227,35	164,91	11,06	$-10{,}02$	50,6%
	6	253,98	180,73	11,94	$-14{,}78$	49,4%
Sazonal ingênuo	1	295,52	222,57	15,89	$+96{,}08$	34,4%
	2	295,52	222,57	15,89	$+96{,}08$	34,4%
	3	295,52	222,57	15,89	$+96{,}08$	34,4%
	6	295,52	222,57	15,89	$+96{,}08$	34,4%

Nota: RMSE, MAE e viés em máquinas equivalentes; viés positivo indica superestimação. Cada linha usa as mesmas 460 origens, e a máscara do MAPE não excluiu nenhuma. O sazonal ingênuo repete o valor de um dia antes e, por isso, não depende de h.

Tabela A.2: Erro das previsões no teste, por horizonte h.

Previsor	h	**RMSE**	**MAE**	**MAPE (%)**	**Viés**	**Taxa de subestimação**
ARIMA	1	157,44	120,25	7,45	$+1{,}75$	42,9%
	2	190,36	143,76	8,95	$+3{,}15$	45,7%
	3	206,16	157,83	9,88	$+4{,}24$	45,5%
	6	234,88	178,64	11,13	$+6{,}15$	45,9%
GRU	1	162,26	125,56	7,89	$+17{,}59$	39,4%
	2	191,25	146,67	9,27	$+15{,}31$	43,1%
	3	204,36	157,55	9,96	$+13{,}08$	43,1%
	6	229,60	173,90	10,88	$-4{,}40$	47,6%
Ingênuo	1	168,05	126,83	7,81	$+0{,}56$	45,0%
	2	210,23	157,53	9,74	$+1{,}45$	46,5%
	3	229,81	176,29	10,98	$+2{,}68$	46,5%
	6	267,34	203,26	12,71	$+5{,}65$	47,0%
Holt-Winters	1	173,68	133,44	8,24	$-1{,}13$	51,5%
	2	209,23	160,20	9,99	$-1{,}54$	50,9%
	3	221,27	172,81	10,79	$-1{,}92$	50,9%
	6	255,43	199,16	12,42	$-4{,}13$	50,6%
Média móvel	1	187,65	142,68	8,90	$+3{,}01$	46,5%
	2	207,27	158,16	9,88	$+3{,}86$	46,1%
	3	219,73	168,03	10,50	$+4{,}54$	46,5%
	6	242,20	186,24	11,55	$+5{,}37$	46,5%
Sazonal ingênuo	1	360,90	291,42	17,56	$-166{,}41$	66,9%
	2	360,90	291,42	17,56	$-166{,}41$	66,9%
	3	360,90	291,42	17,56	$-166{,}41$	66,9%
	6	360,90	291,42	17,56	$-166{,}41$	66,9%

Nota: RMSE, MAE e viés em máquinas equivalentes; viés positivo indica superestimação. Cada linha usa as mesmas 462 origens, e a máscara do MAPE não excluiu nenhuma. O sazonal ingênuo repete o valor de um dia antes e, por isso, não depende de h.

B
Parâmetros dos previsores e do Projeto Final II

A Tabela B.1 complementa a Tabela 3.3 com os parâmetros dos previsores (OE2) e com as janelas de teste e as sementes da GRU do Projeto Final II (OE8 e OE9), descritas na Seção 3.2.3.

Tabela B.1: Parâmetros dos previsores e das janelas e sementes do Projeto Final II.

Parâmetro	**Símbolo**	**Valor**
Janela (média móvel; GRU)	w	6 intervalos (30 min); 72 intervalos (6 h)
Período sazonal	s	288 intervalos (1 dia); Holt-Winters aditivo
Ordem do ARIMA	(p, d, q)	$(2, 1, 2)$, fixa; resíduos do treino sem autocorrelação até a defasagem 12 (Ljung-Box)
GRU	–	1 camada de 32 unidades e saída linear para $h = 1$ a 6; perda MSE, Adam com taxa 0,001, lotes de 32, até 100 épocas; parada antecipada com paciência de 10 épocas nos últimos 15% das janelas do treino; normalização pela média e pelo desvio padrão do treino
Semente da GRU (PF I)	–	42
Sementes da GRU (PF II)	–	10, de 42 a 51
Janelas de teste na Alibaba (PF II)	–	3 de 1 dia (288 intervalos); treino expansivo; validação de 1 dia
Janelas de teste no Google (PF II)	–	3 a 4 de 2 a 3 dias por célula; treino expansivo de pelo menos 14 dias; validação do tamanho do teste